

Universidad Complutense de Madrid



U N I V E R S I D A D
COMPLUTENSE
M A D R I D

Trabajo Fin de Máster

Análisis y modelización predictiva del valor de mercado de un jugador de fútbol en base a su rendimiento en los partidos

Máster Big Data, Data Science e Inteligencia Artificial - Curso 2025/2026

Elaborado por Jose Manuel Zamora Pulido

1. Introducción y contexto de negocio
 - 1.1 El problema
 - 1.2 Objetivos
 - 1.3. Alcance y delimitación
2. Comprensión de los datos (Data Understanding)
 - 2.1 Fuente y volumetría
 - 2.2. Decisión sobre cada columna
 - 2.3 Auditoría de calidad
 - 2.4 Cobertura temporal
3. Construcción del conjunto analítico
 - 3.1 Unidad de análisis y diseño temporal
 - 3.2 Reconstrucción histórica de las variables de contexto
 - 3.3. Ingeniería de características: rendimiento y rol
 - 3.4. Población de estudio y criterios de filtrado
 - 3.5. Construcción de la variable objetivo y deflactación
4. Análisis exploratorio
 - 4.1. Distribución de la variable objetivo
 - 4.2. La curva de valor por edad
 - 4.3. Persistencia y nivel de mercado
 - 4.4. Redundancia entre predictores
 - 4.5. Efecto del contexto del club sobre el valor
 - 4.6. Valores ausentes y atípicos
5. Modelización y resultados
 - 5.1 Especificaciones
 - 5.2 Estrategia de validación
 - 5.3 Métricas
 - 5.4. Resultados sobre conjunto de test
 - 5.5. Selección del modelo final
6. Interpretabilidad del modelo
 - 6.1 Metodología SHAP y Dinámica Global del Mercado
 - 6.2 Interpretabilidad local: caso práctico
7. Conclusiones y trabajo futuro
 - 7.1. Conclusiones técnicas
 - 7.2. Conclusiones para el ámbito deportivo
 - 7.3. Limitaciones
 - 7.4. Trabajo futuro
8. Bibliografía

1 INTRODUCCIÓN Y CONTEXTO DE NEGOCIO

1.1 El problema

El mercado de fichajes del fútbol profesional europeo moviliza cada temporada millones de euros sin disponer de un precio de referencia objetivo. A diferencia de otros activos, un futbolista no cotiza: su valor sólo se observa cuando se produce una transacción, y esa transacción es única, irrepetible y está condicionada por la urgencia de las partes.

En ausencia de un precio de mercado continuo, el sector recurre a valoraciones estimadas. Una de las referencias más extendida es la que publica Transfermarkt, construida a partir del juicio agregado de una comunidad de usuarios y de un panel de moderadores. Estas valoraciones presentan una correlación elevada con los precios de traspaso realmente pagados, lo que respalda su utilidad práctica, pero el procedimiento que las genera no es transparente ni reproducible: no existe una función explícita que relacione el rendimiento observable de un jugador con la cifra publicada.

Esta opacidad tiene consecuencias operativas. Los clubes toman decisiones de inversión de decenas de millones de euros apoyándose en el criterio del director deportivo y en otras referencias de mercado. La ausencia de un marco objetivo dificulta detectar oportunidades y encarece los errores de valoración.

1.2. Objetivos

El objetivo general es estimar el valor de mercado de un futbolista profesional a partir de su rendimiento en competición, su perfil biofísico y el contexto de su club, identificando mediante técnicas de Machine Learning a aquellos jugadores cuya valoración real se desvía de la cotización que su desempeño empírico justifica.

Los objetivos específicos que vertebran el trabajo son:

- Extraer e integrar las tablas clave de un modelo relacional en un único conjunto analítico reproducible.
- Definir una unidad de análisis (jugador-temporada) y un diseño temporal estricto que impida cualquier fuga de información (data leakage).
- Diseñar variables predictoras avanzadas basadas en el volumen de participación, la eficiencia, el contexto competitivo y el estatus jerárquico del jugador.
- Entrenar y comparar diferentes familias de algoritmos de complejidad creciente, evaluando su capacidad predictiva.
- Garantizar la interpretabilidad del modelo seleccionado (mediante valores SHAP) para desentrañar empíricamente los determinantes estructurales del valor en el mercado de fichajes.
- Analizar un caso práctico de infravaloración utilizando la interpretabilidad local del modelo para desglosar qué factores justifican dicha discrepancia.

1.3. Alcance y delimitación

El estudio se circunscribe a las cinco grandes ligas europeas durante siete temporadas (excluyendo la 2019/20), limitándose a jugadores de campo con una participación mínima. Tal y como se justificará metodológicamente más adelante, se excluyen los guardametas y se descarta el precio real de traspaso como variable objetivo dada su opacidad, utilizando en su lugar tasaciones externas continuas.

2 COMPRENSIÓN DE LOS DATOS (DATA UNDERSTANDING)

2.1. Fuente y volumetría

Se ha utilizado el conjunto *Football Data from Transfermarkt* disponible públicamente en Kaggle bajo licencia CC0 (dominio público) lo que permite su uso académico sin restricciones. Se trata de un proyecto de actualización semanal; el presente trabajo emplea la versión 677, congelada localmente para garantizar la reproducibilidad de los resultados.

El conjunto está organizado como un modelo relacional de doce tablas con granularidades diferentes, de las cuales, ocho de ellas intervienen en el estudio:

Tabla	Registros	¿Qué representa?
game_lineups	3.179.016	Un jugador en la alineación de un partido
appearances	1.894.350	Un jugador en un partido
player_valuations	656.301	Una revisión del valor de un jugador
club_games	177.916	Un club en un partido
games	88.958	Un partido
players	50.149	Un jugador
clubs	796	Un club
competitions	65	Una competición

Tabla 1. Tablas empleadas y su volumen.

La distinción de granularidad es determinante. El conjunto *appearances* debe agregarse, ya que un jugador con treinta y cuatro partidos, en la misma temporada, ocupa treinta y cuatro filas que deben resumirse en una sola observación, debido al diseño del conjunto de datos analítico. En cambio, otros conjuntos como *players* y *clubs* contienen una sola fila por entidad, por lo que basta con consultarlas para incorporar sus atributos.

2.2. Decisión sobre cada columna

Una vez descartadas las otras cuatro relaciones del conjunto de datos, se analizó detenidamente cada una de las columnas de las tablas seleccionadas para el estudio.

En total se evaluaron 117 columnas, las cuales se clasificaron en tres categorías operativas: 72 serán descartadas, 24 se van a usar directamente y 21 han sido catalogadas como auxiliares. Estas últimas son aquellas que se utilizarán, entre otras funciones, principalmente para realizar las agregaciones y uniones necesarias.

Las columnas descartadas corresponden a aquellas que no sirven como clave de cruce ni aportan información relevante para el objetivo del estudio. Tanto los motivos específicos que justifican el descarte de estas variables, como las razones para la inclusión de las columnas que sí se van a usar, se encuentran documentados detalladamente en el Anexo A.

2.3. Auditoría de calidad

En este apartado se presentan los resultados de la auditoría, que verifica que los datos de partida soportan la transformación analítica prevista, garantizando que las agregaciones no arrastren errores de origen. Para ello, se examinó el conjunto bajo tres dimensiones fundamentales:

- **Compleitud:** ausencia total de valores nulos en las columnas críticas (claves de agrupación y variable objetivo). Las variables con ausencias superiores al 5% fueron aisladas para evaluar su viabilidad.
- **Integridad referencial:** las relaciones principales (jugador-aparición-valoración) mostraron una alta cohesión. Se detectaron orfandades acotadas (entre el 9% y 14%) en uniones secundarias, como las alineaciones y los clubes locales, magnitudes que se documentaron para gestionar su impacto en los filtros de población posteriores.
- **Consistencia interna:** se ejecutaron cuatro bloques de validación lógica para detectar imposibles físicos (estaturas o minutos irreales), incoherencias temporales (partidos fechados fuera de su temporada), duplicados lógicos y errores de asignación de clubes. Los resultados confirmaron la fiabilidad de los datos, dado que ninguna de las anomalías evaluadas superó el umbral de tolerancia del 3% fijado para el estudio. Estos resultados se recogen en el Anexo B.

2.4. Cobertura temporal


La dimensión más determinante resultó ser la cobertura, dado que la variable objetivo se define sobre una ventana temporal concreta. El análisis reveló cinco hallazgos, cada uno con su consecuencia directa sobre el diseño:

- Las valoraciones se actualizan en oleadas, no de forma continua: la distribución mensual muestra dos concentraciones anuales, en mayo-junio y en diciembre, coherentes con el mercado de fichajes por jugador y año. La revisión de primavera no ocurre en una fecha única, sino distribuida a lo largo de fechas distintas.
- Las ligas no se revisan simultáneamente: la Premier League y la Bundesliga concluyen antes que las competiciones mediterráneas y se revisan en mayo, mientras que LaLiga, la Serie A y la Ligue 1 se revisan en junio. Una ventana de objetivo iniciada el 1 de junio capturaba correctamente tres ligas y perdía prácticamente por completo las otras dos, reduciéndose así de manera considerable el número de registros disponibles para el estudio.
- La cobertura solo se estabiliza a partir de 2016: el recuento anual de valoraciones crece de forma sostenida durante la década anterior (13.795 en 2010, 23.707 en 2014, 30.479 en 2015) y no supera el umbral de las 34.000 hasta 2016, manteniéndose por encima de esa cifra en todos los ejercicios posteriores. Los años previos no ofrecen una densidad de tasaciones comparable, lo que introduciría un desequilibrio entre temporadas y penalizaría la representatividad de las primeras. En consecuencia, el periodo de estudio se inicia en la temporada 2016/17.
- La ventana objetivo de 2020 se desplomó: registró 3.584 valoraciones frente a las 16.738 del año anterior, consecuencia de la interrupción de las competiciones por la pandemia. La temporada 2019/20 se excluye del estudio.
- Desde 2024 desciende el número de jugadores cubiertos: los jugadores con valoración pasan de 27.890 en 2023 a 19.628 en 2024, mientras que los jugadores con apariciones registradas aumentan en ese mismo periodo. El cruce de ambas series descarta una reducción del ámbito del conjunto y localiza un problema en la captura de valoraciones. El conjunto de prueba se limita en consecuencia a la temporada 2023/24.

3 CONSTRUCCIÓN DEL CONJUNTO ANALÍTICO

3.1 Unidad de análisis y diseño temporal

La unidad de análisis central de este estudio es el binomio jugador-temporada. Cada observación del conjunto analítico consolida el rendimiento acumulado por un futbolista a lo largo de una temporada deportiva (S) con el fin de predecir su valoración de mercado, publicada coincidiendo con la apertura de la ventana de fichajes estival inmediatamente posterior.



Esquema 1: Esquema del diseño temporal

Para garantizar la estricta separación temporal entre las variables predictoras y la variable objetivo — evitando así cualquier fuga de información (data leakage) —, el diseño se rige por dos reglas:

- Ningún predictor emplea información posterior al 1 de mayo del año siguiente: los partidos disputados con posterioridad a esa fecha se excluyen del cómputo de rendimiento, lo que supone renunciar a las tres o cuatro últimas jornadas de cada temporada en determinadas ligas (no en todas). Sin este corte, el rendimiento de esas jornadas sería posterior a la valoración objetivo en las ligas que se revisan antes.
- La ventana del objetivo abarca del 1 de mayo al 15 de julio, tomándose la última valoración disponible en ese intervalo. Su amplitud responde directamente al hallazgo de la auditoría: las ligas no se revisan simultáneamente, y una ventana estrecha excluiría competiciones.

3.2 Reconstrucción histórica de las variables de contexto

Dado que las tablas originales de jugadores y clubes reflejan únicamente el estado presente de cada entidad, la incorporación directa de sus atributos introduciría sesgos temporales. Para evitarlo, el contexto deportivo, económico y demográfico de cada observación se reconstruyó utilizando exclusivamente fuentes históricas fechadas:

- Asignación del club de la temporada: Se descartó el uso de la variable que indica el club actual del jugador, ya que sería incorrecta para futbolistas traspasados o retirados. En su lugar, el club representativo de la temporada se dedujo asignando aquel en el que el futbolista acumuló la mayor cantidad de minutos jugados. A su vez, la liga correspondiente a esa temporada se determinó cruzando dicho club resultante con el catálogo de competiciones domésticas.
- Rendimiento del club en la temporada: El rendimiento colectivo se midió a través de tres métricas: puntos por partido, diferencia de goles y posición relativa en la clasificación. Estos indicadores se calcularon a partir de los resultados reales de los encuentros disputados por el club, aplicando la ventana temporal expuesta en el apartado anterior.
- Dimensión económica de la plantilla: Para sustituir el valor total actual del equipo (dato anacrónico), se reconstruyó el poder económico histórico del club promediando las valoraciones de mercado vigentes al inicio de la temporada de los jugadores de esa plantilla. De manera complementaria, se retuvo el aforo del estadio como variable proxy de la magnitud institucional.
- Perfil demográfico dinámico: La edad del jugador se generó de forma dinámica calculando la diferencia matemática exacta entre el 1 de mayo de la temporada analizada y la fecha de nacimiento del futbolista. De este modo, un mismo jugador presenta edades progresivamente distintas en cada

una de las temporadas que componen su historial.

3.3. Ingeniería de características: rendimiento y rol

La construcción de las variables predictoras requirió transformar los registros individuales de cada partido en métricas agregadas anuales, generando un amplio catálogo de variables estructuradas en seis grandes bloques temáticos:

Bloque	Ejemplos
Perfil	Edad a fecha de corte, altura, posición, subposición, pie dominante
Métricas absolutas	Partidos, minutos, goles, asistencias, tarjetas
Eficiencia	Goles por noventa minutos, asistencias por noventa, contribución de gol
Rol en el club	Minutos por partido, ratio de titularidad, veces capitán
Contexto competitivo	Partidos de liga, partidos europeos, número de competiciones
Contexto del club	Puntos por partido, posición en liga, valor de plantilla, aforo

Tabla 2. Resumen de variables.

Tras asignar cada aparición a su temporada correspondiente y aplicar el corte temporal establecido, la información de rendimiento se consolidó en la unidad jugador-temporada bajo dos ejes analíticos principales:

- Métricas estandarizadas frente a contadores absolutos: La agregación primaria generó contadores de volumen (minutos totales, goles, asistencias y tarjetas), los cuales recompensan la disponibilidad física y la regularidad del futbolista. Sin embargo, para evaluar la productividad aislada del tiempo de juego, se construyeron métricas de eficiencia, dividiendo la producción entre bloques de 90 minutos. Ambas perspectivas —el volumen absoluto y los ratios de eficiencia— se retuvieron deliberadamente en el modelo al aportar señales predictivas complementarias.
- Rol en la plantilla: El estatus jerárquico y táctico del jugador se cuantificó a partir de los datos históricos de las alineaciones. Se definió el ratio de titularidad como la proporción de veces que el futbolista integró el once inicial respecto al total de encuentros en los que fue convocado. Complementariamente, se extrajo el número de veces que ejerció la capitanía.

3.4. Población de estudio y criterios de filtrado

El conjunto inicial de observaciones de jugador-temporada fue sometido a un embudo de filtrado secuencial para acotar la muestra a un entorno homogéneo, representativo y con la robustez estadística necesaria para la modelización. Las restricciones aplicadas y sus respectivas justificaciones metodológicas son las siguientes:

- Restricción a las cinco grandes ligas (Big 5): El análisis se circunscribió exclusivamente a la Premier League, La Liga, Serie A, Bundesliga y Ligue 1 (GB1, ES1, IT1, L1, FR1). Este filtro homogeneiza el ecosistema competitivo, económico y mediático, evitando distorsiones derivadas de ligas periféricas cuyos volúmenes de traspaso y sistemas de valoración presentan grandes desviaciones.
- Exclusión de la temporada 2019/20: Se eliminó por completo este ejercicio del estudio debido a la abrupta interrupción e irregularidad de las competiciones provocada por la pandemia de COVID-19.
- Umbral mínimo de participación (450 minutos): Se exigió que cada jugador acumulara al menos 450 minutos de juego en la temporada (equivalente a cinco partidos completos). Esta condición es

indispensable para la estabilidad de las métricas estandarizadas, ya que volúmenes de minutos menores distorsionan los ratios previamente mencionados.

- Exclusión de porteros: Los guardametas fueron descartados del estudio, reteniendo únicamente a los jugadores de campo (Attack, Midfield, Defender) debido a la gran diferencia que hay para medir su rendimiento.
- Rango de edad biológicamente plausible: Se acotó la muestra a futbolistas con edades comprendidas entre los 15 y los 45 años. Este criterio actúa como un filtro de validación defensiva para descartar errores de registro o anomalías en las fechas de nacimiento procedentes de la fuente original.

3.5. Construcción de la variable objetivo y deflactación

La variable objetivo del modelo se definió como la última tasación de mercado publicada para el jugador en la ventana objetivo mencionada de manera previa. Dado que el mercado futbolístico experimenta variaciones inflacionarias entre distintas temporadas, emplear el valor nominal directo sesgaría el modelo. Para aislar este efecto macroeconómico sin incurrir en fugas de información (data leakage), se construyó un índice de mercado. Este índice se calculó como la mediana de todas las tasaciones de las cinco grandes ligas (Big 5) correspondientes al verano anterior (ventana temporal de la temporada S). A la hora de la implementación, la variable objetivo se normalizó aplicando una transformación logarítmica combinada con la deflactación del índice, materializada mediante la siguiente formulación:

$$y_log_defl = \ln(V) - \ln(I)$$

Donde 'V' representa la valoración nominal del jugador e 'I' el índice de mercado correspondiente. En consecuencia, el modelo no predice una cantidad monetaria absoluta, sino la desviación porcentual logarítmica del jugador respecto a la tendencia general del mercado en ese instante histórico.

El resumen de las variables explicativas de este conjunto analítico se encuentra recogido en el Anexo C.

4 ANÁLISIS EXPLORATORIO

La exploración se realiza sobre el conjunto analítico ya construido, no sobre las tablas de origen. La razón es que la unidad de análisis del estudio es el jugador-temporada, unidad que no existe en los datos en crudo: describir '*appearances*' equivaldría a caracterizar partidos individuales, un objeto que el modelo nunca llega a observar.

4.1. Distribución de la variable objetivo

El valor de mercado presenta una asimetría extrema, con un coeficiente de 3,44. La mediana se sitúa en torno a los seis millones de euros, el percentil 99 alcanza los ochenta millones y el máximo observado son doscientos millones. La ratio entre el percentil 99 y el percentil 1 es de aproximadamente 200 veces.

Sin transformación, cualquier modelo de regresión no rendirá correctamente. Por ello, aplicamos la transformación logarítmica (vista de manera previa en el apartado 3), que reduce la asimetría a $-0,03$, un valor prácticamente simétrico.



Figura 1: Distribución del valor de mercado en escala original y logarítmica

4.2. La curva de valor por edad

La relación entre edad y valor no es monótona. Presenta una fase de revalorización durante los primeros años de carrera, un máximo situado en el entorno de los veintidos a veintisiete años, y un declive posterior pronunciado.

Esta forma es determinante para la elección de modelos: una regresión lineal sin transformar asumiría erróneamente que la edad penaliza o premia el valor de manera constante, lo que es falso. De hecho, la correlación lineal entre edad y valor logarítmico es reducida pese a tratarse de uno de los factores más influyentes, precisamente porque la relación es no monótona.

De aquí se derivan dos decisiones de modelado: la incorporación de “splines cúbicos naturales” sobre la edad en el modelo lineal, y el recurso a modelos basados en árboles, capaces de capturar la forma sin especificarla previamente.




Figura 2: Curva de valor por edad, global y por posición

4.3. Persistencia y nivel de mercado

Para medir la inercia temporal de la variable objetivo y establecer un punto de referencia riguroso, se analiza la persistencia del valor de mercado de los jugadores utilizando su valor previo deflactado frente al valor objetivo actual.

- **Análisis de correlación y persistencia:** al relacionar el logaritmo del valor previo deflactado con el logaritmo del valor objetivo sobre el conjunto completo, se obtiene un coeficiente de correlación de $r = 0,833$, equivalente a un R^2 de 0,694. En la gráfica de dispersión los datos se alinean de forma estrecha respecto a la línea de referencia, lo que confirma la fuerte inercia temporal de la variable objetivo.
- **El listón de referencia:** esa cifra describe la asociación dentro de la muestra, pero no el rendimiento que la regla alcanzaría en un uso real. Evaluada como predictor bajo el mismo esquema out-of-time que el resto de modelos —entrenando con el histórico y prediciendo la temporada 2023/24—, la persistencia obtiene un R^2 de 0,559 (Tabla 4). Este segundo valor, y no el anterior, constituye el listón que deben superar los modelos avanzados, garantizando que cualquier algoritmo implementado aporte un rendimiento superior al de la simple inercia histórica del jugador.
- **Nivel del Mercado Global:** La evolución temporal por temporadas (desde 2016 hasta 2023) muestra las fluctuaciones macroeconómicas generales del mercado futbolístico. Tanto la media como la mediana experimentan un crecimiento pronunciado en los primeros años (hasta 2018) para luego estabilizarse en una meseta en los años posteriores, donde la mediana se sitúa de forma constante alrededor de los 6-7 millones de euros y la media entre los 13 y 14 millones de euros.




Figura 3: Persistencia de la valoración y evolución del nivel de mercado

4.4. Redundancia entre predictores

Para evaluar la colinealidad y la redundancia de información entre las variables explicativas, se analiza la matriz de correlación de Spearman. Este mapa de calor permite identificar grupos de variables fuertemente asociadas, destacando principalmente tres bloques principales: las métricas de participación (minutos, total de partidos y partidos de liga), las métricas de rendimiento normalizado (goles, asistencias y sus tasas por 90 minutos) y las variables institucionales o de club (valor medio, aforo, ranking y puntos por partido).




Figura 4: Matriz de correlación de Spearman entre predictores

4.5. Efecto del contexto del club sobre el valor

El entorno institucional y competitivo ejerce una influencia determinante sobre el valor de mercado de los futbolistas, analizándose a través de tres dimensiones clave:

- Dimensión del club: Al segmentar el valor medio de la plantilla en quintiles, se observa una clara relación monótona ascendente; los jugadores de equipos con mayor potencial financiero ("Muy

alto") presentan distribuciones de valor notablemente superiores frente a los de clubes más modestos ("Muy bajo").

- Competición (Liga): La comparación entre ligas muestra que la competición inglesa (GB1) destaca con una mediana de valor superior respecto al resto de torneos europeos, evidenciando su mayor músculo económico.
- Clasificación del club: La posición en la tabla de la liga muestra un descenso pronunciado y casi exponencial del valor mediano, partiendo de picos cercanos a los 30 millones de euros para los líderes (posición 1) hasta reducirse a unos 2 millones para los últimos clasificados.

Estas evidencias confirman que las variables vinculadas al ecosistema del club actúan como potentes factores contextuales que condicionan de forma directa la tasación individual de los jugadores.




Figura 5: Contexto del club

4.6. Valores ausentes y atípicos

El análisis de calidad de los datos revela la presencia de valores ausentes en un conjunto reducido de variables, con incidencias mínimas que oscilan entre el 0.04% y el 1.17% (afectando a campos como 'dias_mv_prev', 'height_in_cm', 'club_ppp', 'club_dif_g', 'club_rank', 'foot' y 'log_mv_prev'). Para su tratamiento sin comprometer el tamaño de la muestra, se establecen estrategias específicas dentro del flujo de trabajo:

- Variables categóricas: La variable 'foot' incorpora los nulos en una categoría propia de "desconocido", evitando la eliminación de filas.
- Variables numéricas del club: Los campos como 'club_ppp' o 'club_rank' se imputan mediante la mediana integrada directamente en el pipeline de preprocesamiento.
- Valores atípicos en ratios: La revisión de casos extremos en las métricas por 90 minutos (ga_90) muestra que las cifras elevadas responden a jugadores con pocos minutos y alta participación (efecto de denominador pequeño). Este fenómeno se mitiga mediante el filtro previo de 450 minutos, por lo que no se requiere una corrección manual adicional sobre los datos.

5 MODELIZACIÓN Y RESULTADOS

5.1. Especificaciones

Se definen tres conjuntos de variables. No responden a un proceso de selección automática, sino a una decisión metodológica: cada uno responde a una pregunta distinta.

Especificación	Variables	Pregunta que responde
Persistencia	Solo la valoración previa	¿Cuánto se explica sin observar el rendimiento?
Principal	Rendimiento, perfil y contexto	¿Qué predice el rendimiento por sí solo?
Robustez	Todas las anteriores	¿Cuál es el techo alcanzable?

Tabla 3: Especificaciones evaluadas.

La especificación principal es la del trabajo, ya que excluye la valoración previa porque, al capturar la persistencia del mercado, ocultaría la relación entre rendimiento y valor, que constituye el objeto del estudio.

No se realiza selección de variables previa. Se deja que cada algoritmo gestione la irrelevancia mediante sus propios mecanismos.

5.2. Estrategia de validación

Existen dos motivos independientes por los que una partición aleatoria resultaría inadecuada, y ambos se controlan.

- Motivo temporal (validación Out-of-Time): Un reparto aleatorio situaría temporadas futuras en entrenamiento y pasadas en prueba, otorgando al modelo información sobre la evolución del mercado que en un uso real no tendría. Para simular el entorno real de producción —donde solo se dispone del histórico para predecir el futuro—, la partición se realiza estrictamente por temporadas completas: entrenamiento hasta 2021/22, validación en 2022/23 y prueba en 2023/24. Esto garantiza que las métricas de error reflejen el desempeño real del modelo sin ventajas irreales o fugas de información (data leakage). Verificado empíricamente: el mismo Random Forest alcanza $R^2 = 0,859$ con partición aleatoria frente a 0,818 con la partición temporal, un optimismo del 5% que no correspondería a un uso real.
- Motivo de agrupación: El conjunto contiene medidas repetidas. Un reparto aleatorio situaría al mismo jugador en entrenamiento y en prueba, y el modelo memorizaría individuos en lugar de aprender la relación entre rendimiento y valor. La validación cruzada dentro de entrenamiento emplea 'GroupKFold' agrupando por identificador de jugador.

5.3. Métricas

No se emplea el coeficiente de determinación como métrica única. Se reportan el error absoluto medio, el error retrotransformado a euros, el error porcentual absoluto medio y la correlación de Spearman, esta última

especialmente relevante por medir la calidad del ordenamiento.

Al deshacer el logaritmo mediante la función exponencial se obtiene una estimación de la mediana condicionada, no de la media, lo que produce una subestimación sistemática. Se aplica la corrección de Duan, que ajusta el resultado mediante el promedio de las exponenciales de los residuos de entrenamiento.

5.4. Resultados sobre conjunto de test

Especificación	Modelo	MAE (log)	R ²	MAE (M€)	MAPE	Spearman
Persistencia	Persistencia	0,512	0,559	4,75	44,8 %	0,816
Persistencia	CatBoost	0,495	0,671	5,94	71,9 %	0,808
Persistencia	Random Forest	0,517	0,654	6,37	78,8 %	0,807
Principal	MLP + embeddings	0,379	0,837	4,39	34,5 %	0,925
Principal	CatBoost	0,385	0,837	4,37	34,6 %	0,928
Principal	OLS + splines	0,393	0,827	4,33	38,2 %	0,920
Principal	Random Forest	0,408	0,817	5,13	38,0 %	0,913
Robustez	CatBoost	0,256	0,918	2,98	23,7 %	0,960
Robustez	Random Forest	0,284	0,896	3,60	27,9 %	0,944

Tabla 4: Resultados sobre el conjunto de test (temporada 2023/24, 1.844 observaciones).

Cuatro lecturas se desprenden de estos resultados.

- El rendimiento predice el valor mejor que la propia historia de valoración: La especificación principal (CatBoost) alcanza un coeficiente de determinación de 0,837, superando ampliamente tanto a la regla de persistencia (0,559) como al propio modelo CatBoost entrenado únicamente con datos históricos (0,671). Esta diferencia demuestra que el rendimiento en competición es el verdadero motor del valor de mercado.
- La aportación marginal del historial de valoración: La especificación de robustez eleva el R^2 a 0,918. Aunque es el techo del estudio, la mejora marginal aportada por la valoración previa es de apenas ocho puntos respecto a la especificación principal. Esto sugiere que ambas dimensiones son en gran medida redundantes.
- La competitividad del modelo paramétrico: En la especificación principal, la regresión lineal (OLS + splines) logra métricas ($R^2 = 0,827$, MAE = 4,33 M€) prácticamente indistinguibles de algoritmos complejos como CatBoost o MLP. Este resultado evidencia que el tratamiento de las no-linealidades (mediante splines) permite usar modelos de estructura funcional explícita sin sacrificar capacidad predictiva.
- Garantía de ordenamiento (Spearman): Ninguna métrica describe por sí sola la calidad del modelo. Mientras que la regla de persistencia obtiene un engañoso buen MAE (4,75 M€) por acertar en jugadores sin fluctuaciones, falla estrepitosamente en los cambios bruscos (como delata su pobre R^2). En contraste, los modelos de la especificación principal elevan la correlación de Spearman hasta 0,928.




Figura 6: Comparación de modelos por especificación

5.5. Selección del modelo final

CatBoost y la red neuronal presentan un rendimiento comparable en términos de coeficiente de determinación. Se selecciona CatBoost por criterios de utilidad práctica y no por una ventaja significativa en rendimiento predictivo. En particular, permite obtener valores SHAP mediante TreeSHAP, admite la estimación de intervalos predictivos mediante modelos basados en pérdida cuantílica y presenta, en este caso, un menor coste computacional de entrenamiento y una mayor estabilidad. Por tanto, la elección de CatBoost responde principalmente a sus ventajas de interpretabilidad más que a una superioridad en el coeficiente de determinación.

6 INTERPRETABILIDAD DEL MODELO

6.1 Metodología SHAP y Dinámica Global del Mercado

Para comprender las decisiones del algoritmo y garantizar la transparencia del modelo, se ha implementado SHAP (SHapley Additive exPlanations) utilizando la funcionalidad nativa de CatBoost. Dado que el modelo ha sido entrenado prediciendo el logaritmo del valor deflactado del jugador, la interpretación de los valores requiere una premisa fundamental: las contribuciones no son aditivas sobre el precio final en euros, sino que actúan como factores multiplicativos que expanden o contraen la valoración final desde el espacio logarítmico. El modelo basa su toma de decisiones en un núcleo estructural dominado por tres variables principales, seguido de un ajuste fino basado en rendimiento y disponibilidad:




Figura 7: Importancia global de las variables según SHAP

Los determinantes estructurales (Top 3):

- Edad: Los valores bajos (puntos azules, perfiles jóvenes) se agrupan a la derecha del eje neutro, aportando un impulso positivo al valor. Sin embargo, los valores altos (puntos rojos, jugadores veteranos) forman una extensa cola hacia la izquierda que alcanza valores de hasta -2.0 en la escala logarítmica. Esto visualiza un "castigo severo": la juventud suma valor gradualmente, pero el envejecimiento lo destruye de forma mucho más agresiva.
- Valor medio del club: Presenta una separación de impacto casi perfecta. Los jugadores en clubes de alta capacidad financiera (puntos rojos) se sitúan a la derecha, mientras que aquellos en clubes de menor entidad (puntos azules) se agrupan a la izquierda. Esto ilustra cómo el ecosistema financiero del equipo arrastra la valoración del individuo al alza o a la baja por pura inercia.
- Ratio de titularidad: Sigue un patrón análogo al anterior, pero centrado en el estatus competitivo del jugador. Quienes parten habitualmente de inicio (puntos rojos y morados) estiran la valoración positivamente. Por el contrario, los perfiles de rotación o banquillo (puntos azules) empujan con fuerza la predicción hacia el espectro negativo.

Además de la base estructural, el algoritmo se apoya en el impacto en el campo y la continuidad temporal,

detectando dinámicas de mercado asimétricas:

- Goles y Goles por 90 minutos: Ambas variables muestran un comportamiento casi idéntico. Los altos volúmenes de gol y la alta eficiencia (puntos rojos) se extienden claramente hacia la derecha. No obstante, la ausencia de gol (puntos azules) forma un bloque denso justo en el límite neutro (0.0). El modelo entiende el gol como un atributo que encarece, pero no castiga en exceso su falta.
- Partidos de liga: Ejerce como una métrica de penalización, mostrando un patrón inverso al del gol. La inactividad o escasez de partidos (la larga cola de puntos azules) se despliega severamente hacia la zona negativa, llegando hasta -0.7. En contraste, haber jugado la mayoría del calendario (puntos rojos) suma valor positivo, pero manteniéndose mucho más cerca del centro. El algoritmo revela que el mercado castiga drásticamente la falta de participación, restando mucho más valor por no jugar del que se suma por el mero hecho de estar disponible toda la temporada.

6.2 Interpretabilidad local: caso práctico

Se considera candidato aquel jugador cuya tasación publicada queda por debajo del percentil 10 de la distribución predictiva del modelo —es decir, cuya discrepancia excede la propia incertidumbre estimada— y que acumula al menos 900 minutos disputados, filtro que descarta perfiles con métricas inestables. La siguiente figura muestra el gráfico para Matteo Gabbia, un caso donde el modelo estima al alza, arrojando una predicción final ($f(x) = 3.601$) significativamente superior al valor esperado medio del mercado ($E[f(X)] = 2.014$).




Figura 8: Descomposición SHAP de una predicción individual (Matteo Gabbia)

El desglose SHAP muestra que la estimación se construye casi por completo sobre factores estructurales, no sobre el rendimiento individual:

- Anclaje institucional (+0,961): el club_valor_medio de 20,33 millones aporta por sí solo +0,601, reforzado por la diferencia de goles del club (+0,107), sus puntos por partido (+0,102), su segunda posición en liga (+0,093) y el aforo (+0,058). El contexto de club explica en torno al 60 % de los 1,587 puntos que separan la predicción del valor esperado del mercado.
- La edad como segundo multiplicador (+0,364): con 24,53 años el futbolista se sitúa en la franja alta de la curva de carrera.
- El rendimiento individual como refuerzo menor ($\approx +0,16$): la exposición europea (+0,060), las cuatro competiciones disputadas (+0,077), los 2.591 minutos (+0,062), los 35 partidos (+0,057) y el ratio de titularidad del 66,7 % (+0,040) apenas suman un 10 % del total. La posición de defensa introduce el único ajuste negativo (-0,039).

La estimación resultante, 26,88 M€ frente a los 8 M€ publicados, queda con su intervalo al 80 % [16,36 – 38,94] M€ íntegramente por encima de la tasación real: la discrepancia excede la incertidumbre que el modelo reconoce, lo que permite catalogar el caso como candidato a infravaloración y no como error.

7 CONCLUSIONES Y TRABAJO FUTURO

7.1. Conclusiones técnicas

El proceso de modelización y la evaluación metodológica han revelado hallazgos significativos que trascienden el mero rendimiento predictivo del algoritmo. Las principales conclusiones técnicas extraídas del estudio son las siguientes:

- El modelo alcanza un coeficiente de determinación de 0,837 sobre una temporada no observada, con un Error Absoluto Medio (MAE) de 4,37 millones de euros, sin utilizar en ningún momento la valoración previa del jugador.
- La construcción de las variables pesa más que el modelado no lineal: Una regresión lineal con splines alcanza 0,827 frente al 0,837 del mejor modelo.
- Las decisiones de preparación tienen consecuencias mayores que las de modelización: El hallazgo más determinante del trabajo no fue algorítmico, sino la constatación de que las ligas no se revisan simultáneamente. Una ventana de objetivo mal delimitada eliminaba dos de las cinco competiciones del conjunto de prueba sin producir ningún error visible.

7.2. Conclusiones para el ámbito deportivo

Los resultados se resumen en cuatro mensajes accesibles para un perfil no técnico:

- El contexto pesa más que la producción: Dónde juega un futbolista y cuánto juega explican mucho mejor su valoración que los goles y asistencias que acumula.
- La edad es el factor individual más determinante y su efecto no es lineal: El valor alcanza su máximo entre los veintidos y los veintisiete años y decae con rapidez a partir de los treinta.
- La valoración de mercado es notablemente persistente: Buena parte del valor de un jugador en un ejercicio se explica por su valor en el anterior, lo que sugiere una incorporación gradual de la nueva información.
- El modelo orienta pero no dictamina: el intervalo de estimación es amplio, del orden de magnitud del propio valor, y su cobertura empírica sobre la temporada de prueba (73,5 %) queda por debajo del 80 % nominal, lo que refleja la incertidumbre real inherente a valorar un futbolista.

7.3. Limitaciones

A pesar de la robustez del diseño metodológico, el modelo se encuentra sujeto a restricciones inherentes a la naturaleza de los datos y a los compromisos asumidos para evitar sesgos algorítmicos. Las principales limitaciones del estudio son las siguientes:

- Ausencia de variables contractuales y clínicas: La carencia de datos estructurados sobre el tiempo restante de contrato y el historial de lesiones constituye la limitación de mayor impacto del modelo. El análisis de casos individuales revela que buena parte de los residuos extremos (tasaciones que el modelo no logra explicar) responde precisamente a estas dos variables ocultas, fundamentales en la fijación de precios en el mercado real.
- Truncamiento del calendario competitivo: La estricta fijación de corte al 1 de mayo garantiza que el rendimiento medido sea estrictamente anterior a la publicación de las valoraciones. Sin embargo, esta decisión obliga a renunciar a las métricas generadas durante las tres o cuatro jornadas finales de cada temporada, dejando fuera del radar los desenlaces de algunos campeonatos.
- El objetivo es una estimación, no un precio: Las valoraciones de Transfermarkt proceden de un juicio agregado y pueden desviarse de los precios realmente pagados.

7.4. Trabajo futuro

Los resultados obtenidos y las limitaciones expuestas abren diversas vías de investigación para perfeccionar esta herramienta analítica y maximizar su valor en el ámbito de la dirección deportiva. Las líneas de desarrollo más prometedoras incluyen:

- Expansión a mercados periféricos: El análisis de calidad de datos reveló una alta cobertura en competiciones de segundo nivel. Ampliar el alcance del modelo no solo incrementaría la robustez estadística, sino que permitiría explorar ecosistemas donde las asimetrías de información son mucho mayores, concentrando allí las mejores oportunidades de inversión e identificación de talento emergente.
- Integración de métricas de eventos: La sustitución de contadores estadísticos tradicionales por datos espaciotemporales avanzados (como Goles Esperados - xG, Asistencias Esperadas - xA, o impacto en la progresión del balón) dotaría al algoritmo de una capa de eficiencia cualitativa mucho más precisa para aislar el impacto real del futbolista independientemente de la finalización de sus compañeros.
- Inclusión de variables contractuales históricas: El tiempo restante de contrato es un factor determinante en la fijación real de precios. La integración de bases de datos alternativas que registren el histórico de las renovaciones y vencimientos permitiría al algoritmo modelar el efecto de caducidad del vínculo.

8 BIBLIOGRAFÍA

- Cariboo, D. *Football Data from Transfermarkt* [conjunto de datos]. Kaggle, versión 677. Licencia CC0 (dominio público).
Disponible en: <https://www.kaggle.com/datasets/davidcariboo/player-scores>
- Pandas Development Team.
<https://pandas.pydata.org/docs/>
- Scikit-learn Developers.
<https://scikit-learn.org/stable/>
- Yandex. CatBoost documentation.
<https://catboost.ai/docs/>
- Lundberg, S. M. SHAP (SHapley Additive exPlanations) documentation.
<https://shap.readthedocs.io/>
- PyTorch Foundation. PyTorch documentation.
<https://pytorch.org/docs/>
- Duan, N. (1983). Smearing estimate: a nonparametric retransformation method.