



Análisis y modelización predictiva del valor de mercado de un jugador de fútbol en base a su rendimiento en los partidos

Máster en Big Data, Data Science e Inteligencia Artificial - Universidad Complutense de Madrid

Trabajo Fin de Máster - Jose Manuel Zamora Pulido



UNIVERSIDAD
COMPLUTENSE
MADRID

nticmaster



Contexto y planteamiento

EL PROBLEMA

Un futbolista no cotiza: su precio solo se observa en la transacción, que es única e irrepetible.

Las tasaciones de referencia correlacionan con los traspasos reales, pero su procedimiento no es reproducible.

No existe una función explícita que ligue el rendimiento observable con la cifra publicada.

OBJETIVO

Estimar el valor de mercado a partir del rendimiento en competición, el perfil del jugador y el contexto de su club.

Y, sobre todo, cuantificar de forma interpretable qué factores lo determinan.

12.861

observaciones jugador-temporada

5

grandes ligas europeas

7

temporadas (2016/17 – 2023/24)



UNIVERSIDAD
COMPLUTENSE
MADRID

| **nticmaster**



De los datos en bruto al conjunto analítico

01 Fuente

Transfermarkt (Kaggle, v677): 12 tablas relacionales, 8 utilizadas.

02 Auditoría

117 columnas evaluadas: 24 usadas, 21 auxiliares, 72 descartadas.

03 Agregación

De partido a jugador-temporada, con corte de predictores al 1 de mayo.

04 Filtrado

Big 5, sin porteros, ≥ 450 minutos, sin 2019/20 $\rightarrow$ 12.861 observaciones.

HALLAZGO DETERMINANTE

Las ligas no se revisan simultáneamente: Premier y Bundesliga en mayo, LaLiga, Serie A y Ligue 1 en junio.

Una ventana objetivo iniciada el 1 de junio eliminaba dos de las cinco competiciones del conjunto de prueba sin producir ningún error visible.

Ventana definitiva: 1 de mayo – 15 de julio





Exploración y transformación de variables

Asimetría 3,44

La distribución del valor es inmodelable en bruto.

Transformación logarítmica → asimetría -0,03.

Edad no monótona

Máximo en torno a los 22 años y declive posterior.

Splines cúbicos en el modelo lineal; árboles en el resto.

Deflactación

El mercado se infla entre temporadas.

$y = \ln(V) - \ln(I)$: se predice desviación, no euros.

CONTEXTO RECONSTRUIDO CON FUENTES HISTÓRICAS FECHADAS

El club de la temporada se deduce por minutos acumulados, no por el club actual; el poder económico, promediando las valoraciones vigentes al inicio de temporada; la edad, a fecha de corte. Seis bloques de variables: perfil, producción, eficiencia, rol, contexto competitivo y contexto de club.



Modelización y estrategia de validación

TRES ESPECIFICACIONES

Persistencia — solo la valoración previa.

Principal — rendimiento, perfil y contexto.

Robustez — todas las anteriores.

VALIDACIÓN OUT-OF-TIME

Partición por temporadas completas (entrenamiento $\leq$ 2021/22, validación 2022/23, prueba 2023/24) y

GroupKFold por jugador.

Partición aleatoria: R^2 0,859 frente a 0,818 temporal

→ 5 % de optimismo irreal.

Modelo	MAE (log)	R^2	Spearman
Persistencia	0,512	0,559	0,816
CatBoost	0,385	0,837	0,928
MLP + embeddings	0,379	0,837	0,925
OLS + splines	0,393	0,827	0,920
Random Forest	0,408	0,817	0,913

Especificación principal sobre el conjunto de prueba (2023/24, 1.844 observaciones). CatBoost se selecciona por interpretabilidad, no por ventaja predictiva.




Interpretabilidad: determinantes globales

NÚCLEO ESTRUCTURAL

Edad · Valor medio de la plantilla · Ratio de titularidad

El contexto y la continuidad explican el valor mejor que los goles.



Un caso de infravaloración

CRITERIO

Tasación por debajo del percentil 10 de la distribución predictiva y al menos 900 minutos.


8,00 M€

tasación real

26,88 M€

estimación

Intervalo al 80 % [16,4 – 38,9] M€, íntegramente por encima de la tasación publicada.



UNIVERSIDAD
COMPLUTENSE
MADRID

nticmaster



Gracias por la atención



UNIVERSIDAD
COMPLUTENSE
MADRID

| **ntic**master